

Lab 4.1: Hive Warehouse

Chloé LESTIC

```
PS C:\Users\chloe> ssh l.chloe-ece@edge-1.au.adaltas.cloud
(l.chloe-ece@edge-1.au.adaltas.cloud) Password:
Last login: Tue Feb 10 08:09:53 2026 from 10.0.0.8
[l.chloe-ece@edge-1 ~]$ hdfs dfs -ls /education/$GROUP/resources/lab4/nyc_drivers
Found 1 items
-rw-r--r--  2 t.ece_2026_spring_gr01-ece ece_2026_spring_gr01      2043 2026-01-21 16:31 /education/ece_2026_spring_gr01/resources/lab4/nyc_drivers/drivers.csv
[l.chloe-ece@edge-1 ~]$ hdfs dfs -cat /education/$GROUP/resources/lab4/nyc_drivers/drivers.csv | head -n 5
driverId,name,ssn,location,certified,wage-plan
10,George Vetticaden,621011971,244-4532 Nulla Rd.,N,miles
11,Jamie Engesser,262112338,366-4125 Ac Street,N,miles
12,Paul Coddin,198041975,Ap #622-957 Risus. Street,Y,hours
13,Joe Niemiec,139907145,2071 Hendrerit. Ave,Y,hours
[l.chloe-ece@edge-1 ~]$ hdfs dfs -cp /education/$GROUP/resources/lab4/nyc_drivers /user/$USER/
[l.chloe-ece@edge-1 ~]$ echo $USER
l.chloe-ece
[l.chloe-ece@edge-1 ~]$ echo $GROUP
ece_2026_spring_gr01
[l.chloe-ece@edge-1 ~]$ hdfs dfs -ls /user/$USER/nyc_drivers
Found 1 items
-rw-r--r--  2 l.chloe-ece hdfs      2043 2026-03-16 13:45 /user/l.chloe-ece/nyc_drivers/drivers.csv
[l.chloe-ece@edge-1 ~]$ beeline
SLF4J: Class path contains multiple SLF4J bindings.
SLF4J: Found binding in [jar:file:/usr/hdp/3.1.0.0-78/hive/lib/log4j-slf4j-impl-2.10.0.jar!/org/slf4j/impl/StaticLoggerBinder.class]
SLF4J: Found binding in [jar:file:/usr/hdp/3.1.0.0-78/hadoop/lib/slf4j-log4j12-1.7.25.jar!/org/slf4j/impl/StaticLoggerBinder.class]
SLF4J: See http://www.slf4j.org/codes.html#multiple_bindings for an explanation.
SLF4J: Actual binding is of type [org.apache.logging.slf4j.Log4jLoggerFactory]
Connecting to jdbc:hive2://zoo-1.au.adaltas.cloud:2181,zoo-2.au.adaltas.cloud:2181,zoo-3.au.adaltas.cloud:2181/default;principal=hive/_HOST@AU.ADALTAS.CLOUD;serviceDiscoveryMode=zooKeeper;zooKeeperNamespace=hiveserver2
26/03/16 13:46:35 [main]: INFO jdbc.HiveConnection: Connected to hive-s2-1.au.adaltas.cloud:10000
Connected to: Apache Hive (version 3.1.0.3.1.0.0-78)
Driver: Hive JDBC (version 3.1.0.3.1.0.0-78)
Transaction isolation: TRANSACTION_REPEATABLE_READ
Beeline version 3.1.0.3.1.0.0-78 by Apache Hive
0: jdbc:hive2://zoo-1.au.adaltas.cloud:2181,z> SET hivevar:user=l.chloe-ece
. . . . .> SET hivevar:group=ece_2026_spring_gr01
. . . . .> SET hivevar:hiveUsername=chloe_lestic_ece;
No rows affected (0.081 seconds)
0: jdbc:hive2://zoo-1.au.adaltas.cloud:2181,z>
```

Sur cette capture d'écran nous voyons les réponses aux question 1 à 4. Nous avons tout d'abord affiché les données présentes dans '/education/\$GROUP/resources/lab4/nyc_drivers/drivers.csv',

On regarde ensuite les 5 premières lignes du fichier, on remarque la manière dont le csv a été construit, cela nous servira pour la suite.

Puis nous avons copié le fichier nyc_drivers dans le fichier \$USER (espace personnel) avec :
hdfs dfs -cp /education/\$GROUP/resources/lab4/nyc_drivers /user/\$USER/

On fait ensuite un echo pour afficher le nom d'utilisateur et le groupe.

On ouvre ensuite hive avec « beeline » et on met les variables user=l.chloe-ece ; group = ece_2026_spring_gr01 et le username = chloe_lestic_ece

5. On crée une table externe dans laquelle on récupère les informations du fichier, on prend donc les mêmes noms de colonnes que l'on avait trouvé lorsque l'on avait regardé les premières lignes du fichier csv, on se met bien dans notre espace personnel.

```
0: jdbc:hive2://zoo-1.au.adaltas.cloud:2181,z> CREATE EXTERNAL TABLE chloe_lestic_ece_nyc_drivers_ext (
. . . . .> driverId INT,
. . . . .> name STRING,
. . . . .> ssn STRING,
. . . . .> location STRING,
. . . . .> certified STRING,
. . . . .> `wage-plan` STRING
. . . . .> )
. . . . .> ROW FORMAT SERDE 'org.apache.hadoop.hive.serde2.OpenCSVSerde'
. . . . .> STORED AS TEXTFILE
. . . . .> LOCATION '/user/l.chloe-ece/nyc_drivers'
. . . . .> TBLPROPERTIES ('skip.header.line.count'='1');
```

6. On vérifie que Hive lit correctement le fichier CSV via la table externe, on doit voir les vraies données et pas des NULL.

Tout d'abord on exécute « SHOW TABLES ; » et on voit toutes les tables créées, la notre fait bien parti de la liste

tab_name
a_benatar_ece_nyc_drivers
a_benatar_ece_nyc_drivers_ext
air_quality_louis
b_mathis_ece_nyc_drivers_ext
c_mathis_ece_nyc_drivers_ext
chloe_lestic_ece_nyc_drivers_ext
cmathisece_nyc_drivers_ext
d_ferdinand_ece_nyc_drivers_ext
g_rayan_ece_nyc_drivers_ext
imdb_name_basics
imdb_title_basics
imdb_title_crew
imdb_title_ratings
l_a_pia_ece_nyc_drivers
l_a_pia_ece_nyc_drivers_ext
l_firstname_school_nyc_drivers_ext
l_louis_ece_nyc_drivers_ext
m_edouard_ece_nyc_drivers
m_edouard_ece_nyc_drivers_ext
tk_hugo_ece_nyc_drivers
tk_hugo_ece_nyc_drivers_ext
v_denis_ece_nyc_drivers
v_denis_ece_nyc_drivers_ext

Puis on vient afficher ce qu'il y a dans notre table :

```
SELECT * FROM chloe_lestic_ece_nyc_drivers_ext;
```

On obtient donc :

chloe_lesitic_ece_nyc_drivers_est.driverid	chloe_lesitic_ece_nyc_drivers_est.name	chloe_lesitic_ece_nyc_drivers_est.ssn	chloe_lesitic_ece_nyc_drivers_est.location	chloe_lesitic_ece_nyc_drivers_est.certified	chloe_lesitic_ece_nyc_drivers_est.wage-plan
10	George Vatticaden	621011971	240-4032 Hulla Rd.	N	milos
11	Janie Engesser	262112338	366-4123 Ac Street	N	milos
12	Paul Coddin	130801075	Ap 8622-837 Hiusa Street	Y	hours
13	Joe Niesioc	1390071405	2071 Mendrentit Ave	Y	hours
14	Adis Cudic	130612280	Ap 4810-1230 1e St.	Y	hours
15	Rohit Baisahi	1390065227	608-5681 Dul- Rd	Y	hours
16	Tom McCuch	1633031405	P. O. Box 332- 962 Parturient Rd.	Y	hours
17	Eric Mizell	123800238	P. O. Box 579- 1191 Gravida Street	Y	hours
18	Grant Liu	171021021	Ap 8720-2109 Vestibulum Av.	Y	hours
19	Ajay Singh	160805158	592-9420 Nonummy Avenue	Y	hours
20	Chris Murda	921012280	880-2001 Proin Avenue	Y	hours
21	Jeff Marichan	260000066	Ap 4852-7966 Facillisis St.	Y	hours
22	Kudem Asghar	921020200	350-7047 Aliquam Ave	Y	hours
23	Aden Siat	720212208	P. O. Box 260- 6177 Vitae Road	Y	hours
24	Don Hilburn	260112152	4361 Ac Road	Y	hours
25	Jean-Philippe Playe	921210051	P. O. Box 612- 6238 Ac Rd.	Y	hours
26	Michael Aube	1247051401	P. O. Box 213- 8948 Nec Ave	Y	hours
27	Mark Leuchthaler	392001359	8388 Ipsum St.	Y	hours
28	Olivier Renault	930008181	P. O. Box 243- 6509 Erat Avenue	Y	hours
29	Teddy Choi	185021392	P. O. Box 186- 7803 Amet Rd.	Y	hours
30	Dan Rice	282307061	Ap 8881-9207 Mollis Avenue	Y	hours
31	Rommel Garcia	830012381	P. O. Box 900- 6015 Sociis St.	Y	hours
32	Ryan Templeton	200204207	765-0509 Egestas Av.	Y	hours
33	Elizabeth Rabbella	907000015	Ap 4079-2207 Sagittis Avenue	Y	hours
34	Frank Romano	391007216	Ap 4703-0011 Quis Ave	Y	hours
35	Earl Siewe	971001121	321-2076 Fella Rd.	Y	hours
36	Andrea Grande	240302216	Ap 4085-9098 Egestas Rd.	Y	hours
37	Wes Floyd	130000006	P. O. Box 200- 8011 Hulla Street	Y	hours
38	Scott Shaw	186011175	276 Lobortis Road	Y	hours
39	David Kaiser	907000052	9185 At Street	Y	hours
40	Nicolas Mallard	100710052	3077 Duis Rd.	Y	hours
41	Greg Phillips	200100217	P. O. Box 067- 5961 Arcu Road	Y	hours
42	Benny Galvanen	183102216	340-4100 In Avenue	Y	hours
43	Dave Patton	977000052	3028 A- St.	Y	hours

On voit bien que les informations contenues dans le csv ont été mises complètement dans notre table, sa création est donc validée.

PART 2 : Create a managed ORC table

1. On commence par créer une nouvelle table, cette fois-ci c'est une table gérée en format ORC qui est différente car : la table est gérée par Hive et les fichiers seront stockés dans le dossier Hive du warehouse.

```
0: jdbc:hive2://zoo-1.au.adaltas.cloud:2181,z> CREATE TABLE chloe_lesitic_ece_nyc_drivers (
. . . . .> driverId INT,
. . . . .> first_name STRING,
. . . . .> last_name STRING,
. . . . .> ssn STRING,
. . . . .> address STRING,
. . . . .> certified BOOLEAN,
. . . . .> 'wage-plan' STRING
. . . . .> )
. . . . .> STORED AS ORC;
INFO : Compiling command(queryId=hive_20260316143230_d78d0493-1fe9-4b58-a4b1-371d1115dac5): CREATE TABLE chloe_lesitic_ece_nyc_drivers (
driverId INT,
first_name STRING,
last_name STRING,
ssn STRING,
address STRING,
certified BOOLEAN,
'wage-plan' STRING
)
STORED AS ORC
INFO : Semantic Analysis Completed (retrial = false)
INFO : Returning Hive schema: Schema(fieldSchemas:null, properties:null)
INFO : Completed compiling command(queryId=hive_20260316143230_d78d0493-1fe9-4b58-a4b1-371d1115dac5); Time taken: 0.073 seconds
INFO : Executing command(queryId=hive_20260316143230_d78d0493-1fe9-4b58-a4b1-371d1115dac5): CREATE TABLE chloe_lesitic_ece_nyc_drivers (
driverId INT,
first_name STRING,
last_name STRING,
ssn STRING,
address STRING,
certified BOOLEAN,
'wage-plan' STRING
)
STORED AS ORC
INFO : Starting task [Stage-0:DDL] in serial mode
INFO : Completed executing command(queryId=hive_20260316143230_d78d0493-1fe9-4b58-a4b1-371d1115dac5); Time taken: 0.166 seconds
INFO : OK
No rows affected (0.271 seconds)
0: jdbc:hive2://zoo-1.au.adaltas.cloud:2181,z> |
```

2. Vérifions que la table a été créée dans HDFS à l'adresse suivante
`/warehouse/tablespace/managed/hive/${GROUP}.db/${hiveUsername}_nyc_drivers``
On utilise la commande `ls` pour cette vérification et on obtient :

```
[l.chloe-ece@edge-1 ~]$ hdfs dfs -ls /warehouse/tablespace/managed/hive/ece_2026_spring_gr01.db/chloe_lesitic_ece_nyc_drivers
[l.chloe-ece@edge-1 ~]$ |
```

Comme attendu, le fichier est vide car on n'a pas encore rempli la table

PARTIE 3: Load data from the CSV table to the ORC table

1. On vient remplir notre table avec les transformations demandées :

name → first_name + last_name

location → address

certified de STRING vers BOOLEAN

2. On lance la commande suivante :

```
0: jdbc:hive2://200-1-adu.datas.cloud:2181,25> INSERT INTO TABLE chloe_lestic_ece_nyc_drivers
> SELECT
>     driverId,
>     split(name, ' ')[0] AS first_name,
>     split(name, ' ')[1] AS last_name,
>     ssn,
>     location AS address,
>     CASE
>         WHEN lower(certified) = 'true' THEN true
>         WHEN lower(certified) = 'false' THEN false
>         ELSE NULL
>     END AS certified,
>     'mage-plan'
> FROM chloe_lestic_ece_nyc_drivers_ext;
INFO : Compiling command(queryId=hive_20260316144503_97a945be-9d8a-4a4d-8520-4d077f15d132): INSERT INTO TABLE chloe_lestic_ece_nyc_drivers
```

3. Une fois l'insertion terminée, on vérifie que les données sont bien présentes dans la table managée ORC avec « SELECT * FROM chloe_lestic_ece_nyc_drivers; »

chloe_lestic_ece_nyc_drivers.driverId	chloe_lestic_ece_nyc_drivers.first_name	chloe_lestic_ece_nyc_drivers.last_name	chloe_lestic_ece_nyc_drivers.ssn	chloe_lestic_ece_nyc_drivers.address	chloe_lestic_ece_nyc_drivers.certified	chloe_lestic_ece_nyc_drivers.mage-plan
10	George	Vetticaden	621011971	200-0032 Nalla Rd.	NULL	hours
11	Ande	Eggenes	262112138	300-0120 Ac Street	NULL	hours
12	Paul	Caddin	1800041975	Ap 8022-907 Rinas Street	NULL	hours
13	Joe	Honac	139907140	2073 Montclair Ave	NULL	hours
14	Adis	Keir	820012289	Ap 8010-1220 Le St.	NULL	hours
15	Rebitt	Rebitt	239005287	000-0001 Qui Rd.	NULL	hours
16	Tim	McCuch	363303185	P.O. Box 313- 962 Parturient Rd.	NULL	hours
17	Erie	Mirell	131000240	P.O. Box 079- 2194 Gravida Street	NULL	hours
18	Geant	Lia	171010101	Ap 8020-3039 Vestibulum Av.	NULL	hours
19	Ajay	Sirph	100005130	592-9030 Rummy Avenue	NULL	hours
20	Chris	Harris	02112200	802-2001 Ruyte Avenue	NULL	hours
21	Jeff	Marckan	209000006	Ap 8002-7966 Facillia St.	NULL	hours
22	Nadeem	Agphae	702006209	150-9107 Alloum Ave	NULL	hours
23	Adam	Diaz	920312200	P.O. Box 200- 6127 Vitae Road	NULL	hours
24	Don	Hillbert	20012102	0201 Ac Road	NULL	hours
25	Jean-Philippe	Playe	913110001	P.O. Box 012- 6230 Ac Rd.	NULL	hours
26	Michael	Abbe	120700100	P.O. Box 213- 0900 Nec Ave	NULL	hours
27	Mark	Loebkshier	300001000	0100 Lopus St	NULL	hours
28	Olivier	Demault	099000101	P.O. Box 240- 0000 East Avenue	NULL	hours
29	Teddy	Civil	100002102	P.O. Box 100- 7001 Ruar Rd.	NULL	hours
30	Dan	Rice	202007001	Ap 8001-9207 Pellis Avenue	NULL	hours
31	Rommel	Garcia	00012101	P.O. Box 900- 0010 Sociis St.	NULL	hours
32	Ryan	Templeton	200304207	700-0000 Egestas Av.	NULL	hours
33	Elizabeth	Labella	007000000	Ap 0077-0007 Tempita Avenue	NULL	hours
34	Franko	Romano	301007216	Ap 0700-0010 Quis Ave	NULL	hours
35	Emil	James	070001101	220-0070 Filla Rd.	NULL	hours
36	Andrew	Grande	200303216	Ap 8000-0000 Egestas Rd.	NULL	hours
37	Wes	Playd	100000070	P.O. Box 200- 9011 Nalla Street	NULL	hours
38	Scott	Shaw	300011170	270 Lobortis Road	NULL	hours
39	David	Waiser	007700002	9100 At Street	NULL	hours
40	Nicolas	Phillip	20010217	1027 Quis Rd.	NULL	hours
41	Greg	Phillips	300303116	P.O. Box 007- 0001 Arcu. Road	NULL	hours
42	Nancy	Delbaum	003002200	100-0000 Ruy Avenue	NULL	hours
43	Dave	Puttan	077700002	3020 At St.	NULL	hours

On voit sur la capture d'écran que cela affiche bien les données que l'on souhaite.

4. Après l'insertion, la table managée ne sera plus vide.
Hive aura créé des fichiers ORC dans le dossier HDFS de la table.

```
l.chloe-ec@edge-1 ~]$ hdfs dfs -ls /warehouse/tablespace/managed/hive/ece_2026_spring_gr01.db/chloe_lestic_ece_nyc_drivers
Found 1 items
drwxrwx--- - l.chloe-ec@hadoop 0 2026-03-16 14:45 /warehouse/tablespace/managed/hive/ece_2026_spring_gr01.db/chloe_lestic_ece_nyc_driver
s/delta_00000001_00000001_0000
l.chloe-ec@edge-1 ~]$
```

On voit bien (en comparaison à l'instant où nous avons juste créé la table mais qu'elle était vide), que cette fois il y a la table qui apparaît).