

Lab 4.2: Hive Query Language

Chloé LESTIC

On va commencer par se placer au bon endroit et afficher toutes les tables qui y sont disponibles :

USE ece_2026_spring_gr01; pour se mettre dans le bon emplacement

SHOW TABLES; pour afficher les tables disponibles

```
imdb_name_basics
imdb_title_basics
imdb_title_crew
imdb_title_ratings
```

1. On souhaite voir tous les titres de films qui durent plus de 2h, ainsi on sait que 2h = 120 minutes, on va donc compter tous les titres dont runtimeMinutes > 120.

```
0: jdbc:hive2://zoo-1.au.adaltas.cloud:2181,z> SELECT COUNT(*) AS nb_titles_over_2h
. . . . .> FROM imdb_title_basics
. . . . .> WHERE runtimeMinutes > 120;
```

On obtient donc :

```
+-----+
| nb_titles_over_2h |
+-----+
| 151676            |
+-----+
```

Il y a donc 151676 films qui durent plus de 2h.

2. On cherche la moyenne de durée des films contenant le mot world. On veut les titres qui contiennent le mot world comme mot entier, pas juste comme morceau dans un autre mot.:

- World War Z → oui
 - Underworld → non
- Pour ça on utilise RLIKE

```
0: jdbc:hive2://zoo-1.au.adaltas.cloud:2181,z> SELECT AVG(runtimeMinutes) AS avg_duration_world
. . . . .> FROM imdb_title_basics
. . . . .> WHERE primaryTitle RLIKE '([^A-Za-z])world([^A-Za-z]|$)'
. . . . .> OR originalTitle RLIKE '([^A-Za-z])world([^A-Za-z]|$)';
```

On obtient donc une moyenne de 25,6 minutes.

```
+-----+
| avg_duration_world |
+-----+
| 25.602094240837697 |
+-----+
```

3. Dans IMDb, la colonne genres contient souvent plusieurs genres séparés par des virgules :
Donc on ne cherche pas genres = 'Comedy', mais les lignes où Comedy est présent dans la liste.

On joint imdb_title_basics et imdb_title_ratings avec la clé tconst.

```
0: jdbc:hive2://zoo-1.au.adaltas.cloud:2181,z> SELECT AVG(r.averageRating) AS avg_rating_comedy
. . . . .> FROM imdb_title_basics b
. . . . .> JOIN imdb_title_ratings r
. . . . .> ON b.tconst = r.tconst
. . . . .> WHERE array_contains(b.genres, 'Comedy');
```

On obtient une moyenne de notes de 6,88.

```
+-----+
| avg_rating_comedy |
+-----+
| 6.888439862010231 |
+-----+
```

4. Même logique que la question 3, mais on exclut les films Comedy.

```
0: jdbc:hive2://zoo-1.au.adaltas.cloud:2181,z> SELECT AVG(r.averageRating) AS avg_rating_non_comedy
. . . . .> FROM imdb_title_basics b
. . . . .> JOIN imdb_title_ratings r
. . . . .> ON b.tconst = r.tconst
. . . . .> WHERE NOT array_contains(b.genres, 'Comedy');
```

On obtient une moyenne de 6,97.

```
+-----+
| avg_rating_non_comedy |
+-----+
| 6.970526069596711 |
+-----+
```

5. On cherche les 5 meilleurs films de Tarantino, pour cela il faut utiliser 4 tables :

On veut :

- trouver Quentin Tarantino dans imdb_name_basics
- regarder dans imdb_title_crew les titres où son nconst est dans director
- récupérer le titre dans imdb_title_basics
- récupérer la note dans imdb_title_ratings
- garder seulement les movie
- trier par meilleure note

Étape 1 — trouver Quentin Tarantino

```
0: jdbc:hive2://zoo-1.au.adaltas.cloud:2181,z> SELECT *
. . . . .> FROM imdb_name_basics
. . . . .> WHERE primaryName = 'Quentin Tarantino';
```

On obtient nconst=nm000233 que nous allons réutiliser dans la deuxième étape

imdb_name_basics.nconst	imdb_name_basics.primaryname	imdb_name_basics.birthyear	imdb_name_basics.deathyear	imdb_name_basics.primaryprofession	imdb_name_basics.knownfortitles
nm0000233	Quentin Tarantino	1963	NULL	["writer,producer,actor"]	["tt0105236,tt0110912,tt7131622,tt0116367"]

Étape 2 — Top 5 films de Tarantino

```
3 rows selected (8.207 seconds)
0: jdbc:hive2://zoo-1.au.adaltas.cloud:2181,z> SELECT
. . . . .> b.primarytitle,
. . . . .> r.averagerating,
. . . . .> r.numvotes
. . . . .> FROM imdb_title_crew c
. . . . .> JOIN imdb_title_basics b
. . . . .> ON c.tconst = b.tconst
. . . . .> JOIN imdb_title_ratings r
. . . . .> ON b.tconst = r.tconst
. . . . .> WHERE array_contains(c.director, 'nm0000233')
. . . . .> AND b.titletype = 'movie'
. . . . .> ORDER BY r.averagerating DESC, r.numvotes DESC
. . . . .> LIMIT 5;
```

On obtient :

b.primarytitle	r.averagerating	r.numvotes
Kill Bill: The Whole Bloody Affair	8.8	29185
Pulp Fiction	8.8	NULL
Django Unchained	8.5	NULL
Inglourious Basterds	8.4	NULL
Reservoir Dogs	8.3	NULL

Le meilleur film de tarantino est Kill Bill avec une note de 8.8 il est exaequo avec Pulp Fiction.